



Experimentação Florestal (FL03034 - EF)



🌿 Análise Exploratória de Dados 🌿 (Uma breve revisão)

Prof. Dr. Deivison Venicio Souza

Universidade Federal do Pará (UFPA)

Faculdade de Engenharia Florestal

Laboratório de Manejo Florestal, Tecnologias e Comunidades Amazônicas

E-mail: deivisonvs@ufpa.br



1ª versão: 11/agosto/2021
(Atualizado em: 06/outubro/2026)
Altamira, Pará



Ementa da disciplina (FL03034 - EF)

- 1 - Introdução à experimentação;
- 2 - Análise exploratória de dados;**
- 3 - Delineamento inteiramente casualizado - DIC;
- 4 - Delineamento em blocos ao acaso - DBC;
- 5 - Delineamento em quadrado latino - DQL;
- 6 - Testes de comparação de médias;
- 7 - Experimentos em esquema fatorial;
- 8 - Análise de correlação e regressão linear; e
- 9 - Análise de experimentos com linguagem R.

Objetivos

Ao final desta aula espera-se que o discente seja capaz de...

- Recordar terminologias e conceitos básicos de estatística descritiva;
- Recordar e calcular as principais medidas de tendência central (ou posição); e
- Recordar e calcular as principais medidas de dispersão (ou variabilidade).

Conteúdo

Parte 1 - Terminologias e conceitos básicos

1 - O que é estatística?

2 - Estatística descritiva e Estatística inferencial

3 - População e Amostra

4 - Variável e Parâmetro

5 - Tipos de Variáveis

Parte 2 - Medidas de tendência central (ou posição)

1 - Conceito e importância

2 - Moda

3 - Mediana

4 - Média Aritmética

Conteúdo

Parte 3 - Medidas de dispersão (ou variabilidade)

1 - Conceito e importância

2 - Amplitude Total

4 - Variância

5 - Desvio Padrão

6 - Coeficiente de Variação

Leitura complementar


Livro recomendado

Morettin, Pedro Alberto; Bussab, Wilton Oliveira.
Estatística básica. 9 ed., São Paulo: Saraiva, 2017,
554p.

Parte 1 - Análise Exploratória de Dados (Capítulos 2 e 3).

Dados, códigos R (e outros) podem ser
acessados em:

Link: [Estatística básica](#)



Parte 1

Terminologias e conceitos básicos



Terminologias e conceitos básicos

Conceito

A estatística serve para ajudar na **descrição de fenômenos** e na **tomada de decisões**.

Divisões da estatística

A estatística é, em geral, dividida em dois grandes grupos:

1. Estatística Descritiva
2. Estatística Inferencial

Terminologias e conceitos básicos

Estatística Descritiva

É a parte da estatística que lida com a **organização, resumo e apresentação** de dados.

👉 Os dados podem ser resumidos de forma numérica ou gráfica.

Terminologias e conceitos básicos

Dados de Cedrela odorata.

D ♦	H ♦	V ♦	QF ♦
83	9	4.56	I
90.4	18	7.68	I
95.17	14	6.71	I
86.58	16	5.16	II
96.45	14	5.81	II
57.93	17	2.91	II
76.39	14	5.12	II
76.08	16	4.8	I
76.39	15	4.1	I
66.85	18	3.44	III

Showing 1 to 10 of 32 entries

Previous

1

2

3

4

Next

Como extrair informações descritivas?

- Calcular medidas descritivas quantitativas.

```
# Usando funções da linguagem R
mean(cedrela$D)
## [1] 84.57219
sd(cedrela$D)
## [1] 19.51946
var(cedrela$H)
## [1] 7.096774
table(cedrela$QF)
##
##      I      II     III
##     14     10      8
```

Terminologias e conceitos básicos


Como extrair informações descritivas?

- Usar representações gráficas

```
# Criando um BoxPlot Univariado

g1 <- cedrela %>%
  ggplot(aes(x = 1, y = D)) +
  geom_boxplot() +
  xlab(NULL) +
  theme_bw() +
  theme(
    axis.text.x = element_blank(),
    axis.ticks.x = element_blank()
  )

plotly::ggplotly(g1)
```




Terminologias e conceitos básicos

Como extrair informações descritivas?

- Usar representações gráficas

```
# Criando um Histograma Univariado

g2 <- cedrela %>%
  ggplot(aes(x = H)) +
  geom_histogram(bins = 5, fill="#69b3a2",
                 color="#e9ecef", alpha=0.9) +
  theme_bw()
plotly::ggplotly(g2)
```




Terminologias e conceitos básicos

Como extrair informações descritivas?

- Usar representações gráficas

```
# Criando um Scatterplot  
  
g3 <- cedrela %>%  
  ggplot(aes(x=D, y=V, color=QF)) +  
    geom_point(size = 3) +  
    theme(legend.position="none")  
  
plotly::ggplotly(g3)
```




Terminologias e conceitos básicos

Estatística Inferencial (ou Indutiva)


É a parte da estatística que objetiva inferir sobre uma **população** a partir da observação de uma parte dela (**amostra**).

Terminologias e conceitos básicos

População




Amostra



Terminologias e conceitos básicos

Tipos de Variáveis



Terminologias e conceitos básicos

Variáveis Qualitativas (ou Categóricas)

A variável é qualitativa (ou categórica) quando seus valores são distribuídos em categorias mutuamente exclusivas (Vieira, 2010).

Estas podem ser classificadas em dois tipos:

👉 1 - Variável nominal

👉 2 - Variável ordinal

Terminologias e conceitos básicos

Variáveis Qualitativas (ou Categóricas)

Variável Nominal

A variável é nominal quando seus valores se distribuem em categorias mutuamente exclusivas, indicadas em qualquer ordem (Vieira, 2010).

Variável Ordinal

A variável é ordinal quando os dados são distribuídos em categorias mutuamente exclusivas que possuem ordem (Vieira, 2010).

Terminologias e conceitos básicos

Variáveis Quantitativas (ou Numéricas)

Uma variável quantitativa (ou numérica) é expressa por números que têm significado em uma escala numérica (Vieira, 2010).

Estas podem ser classificadas em dois tipos:

- ➡ 1 - Variável discreta
- ➡ 2 - Variável contínua

Terminologias e conceitos básicos

Variáveis Quantitativas (ou Contínuas)

Variável Discreta

A variável é discreta quando só pode assumir alguns valores em um dado intervalo (Vieira, 2010).

Variável Contínua

A variável é contínua quando pode assumir qualquer valor em um dado intervalo (Vieira, 2010).

Terminologias e conceitos básicos

Vamos praticar...

1 - Dada a tabela abaixo preencha a coluna "Tipo":

Variável	Tipo	Subtipo
Nº de Rebrotos		
Peso de fruto		
Altura da árvore		
Volume de madeira		
Grau de iluminação de copas		
Forma de copas		
Qualidade de fuste		

Showing 1 to 7 of 7 entries

Previous

1

Next

Variável	Tipo	Subtipo
Biomassa		
Mês de observação		
Diâmetro do coleto		
Nome botânico		
Tipos de frutos (Qto à deiscência)		
Diâmetro da árvore		
Nº de sementes germinadas		

Showing 1 to 7 of 7 entries

Previous

1

Next

Parte 2

Medidas de Tendência Central




Medidas de tendência central (ou posição)

Conceito

São medidas que objetivam representar o ponto central (ou de equilíbrio) de uma distribuição de dados.

Principais medidas de posição



Medidas de tendência central (ou posição)

Moda (Mo) - Conceito

É o valor que aparece mais frequentemente em um conjunto de dados.

Qual a moda para a série de dados abaixo?

$\{1, 3, 0, 0, 2, 4, 1, 2, 5, 6, 8, 1, 2, 2, 0\}$

👉 **Como determinar a moda de um conjunto de dados?**

Medidas de tendência central (ou posição)

Moda (Mo) - Como determinar?

- Calcular a frequência de cada valor.
- A moda é o valor mais frequente.

{1, 3, 0, 0, 2, 4, 1, 2, 5, 6, 8, 1, 2, 2, 0}

Valor	Frequência
0	3
1	4
2	3
3	2
4	1
5	1
6	1
8	1

Showing 1 to 8 of 8 entries

Previous 1 Next

Medidas de tendência central (ou posição)

Moda (Mo) - Usando a linguagem R

👉 A linguagem R não possui uma função nativa para calcular a moda.

👉 Mas, pode-se usar a função `table()` para gerar uma tabela de frequências absolutas. Assim, a moda pode ser facilmente identificada.

```
# Cria um vetor
x <- c(1, 3, 0, 0, 2, 4, 1, 2, 5, 6, 8, 1, 2, 2, 0)

# Usar a função "table"
table(x)
## x
## 0 1 2 3 4 5 6 8
## 3 3 4 1 1 1 1 1
```

Medidas de tendência central (ou posição)

Moda (Mo) - Usando a linguagem R

- A função `table()`: gera uma tabela de frequências simples.
- Mas, pode-se criar uma função para retornar o valor modal.

```
# Cria um vetor
x <- c(1, 3, 0, 0, 2, 4, 1, 2, 5, 6, 8, 1, 2, 2, 6)

# Uma função para obter a moda
mod <- function(v) {
  uniq <- unique(v)
  uniq[which.max(tabulate(match(v, uniq)))]
}

# Aplicando a função "mod" ao vetor "x"
mod(x)
## [1] 2
```

Medidas de tendência central (ou posição)

Moda (Mo) - Usando a linguagem R

👉 Podem existir séries de dados em que nenhum valor aparece mais vezes que outros. Nestes casos, diz-se que o conjunto de dados **não possui moda** ou é **amodal**.

Qual a moda para a série de dados abaixo?

{1, 8, 6, 5, 4, 3, 0, 3, 0, 4, 5, 6, 8, 2, 1,2}

```
# Cria um vetor
y <- c(1, 8, 6, 5, 4, 3, 0, 3, 0, 4, 5, 6, 8, 2, 1)

# Usar a função "table"
table(y)
## y
## 0 1 2 3 4 5 6 8
## 2 2 2 2 2 2 2 2
```

Medidas de tendência central (ou posição)

Moda (Mo) - Variáveis qualitativas

👉 A moda pode ser determinada para variáveis qualitativas, ao contrário da média e mediana, por exemplo.

Seja o vetor de nomes de espécies de árvores:

{Marupa, Angelim, Tauari, Marupa, Angelim, Tauari, Marupa, Angelim, Angelim, Angelim, Cedro, Cedro, Cedro, Tauari, Tauari, Marupa}


```
# Cria um vetor
esp <- c(
  "Marupa", "Angelim", "Tauari", "Marupa",
  "Angelim", "Tauari", "Marupa", "Angelim",
  "Angelim", "Angelim", "Cedro", "Cedro",
  "Cedro", "Tauari", "Tauari", "Marupa")

# Usar a função "table"
table(esp)
## esp
## Angelim  Cedro  Marupa  Tauari
##         5      3      4      4
```

Medidas de tendência central (ou posição)

Moda (Mo) - Classificação

Um conjunto de dados pode ser classificado em função da ocorrência (ou não) de **Moda**:



Medidas de tendência central (ou posição)

Moda (Mo) - Classificação

- **Amodal:** Conjunto de dados que **não apresenta moda**. Isto é, nenhum dos valores contidos no conjunto predomina sobre os demais.
- **Unimodal:** Conjunto de dados que **apresenta uma única moda**. Isto é, apenas um dos elementos do conjunto de dados predomina sobre os demais.
- **Bimodal:** Conjunto de dados que **apresenta duas modas**. Isto é, dois dos valores contidos no conjunto de dados predominam sobre os demais;
- **Multimodal:** Conjunto de dados que **apresenta mais de duas modas**. Isto é, mais de dois dos elementos do conjunto de dados predominam sobre os demais.

Medidas de tendência central (ou posição)

Moda (Mo) - Vamos praticar...

Série I: {1, 3, 0, 0, 2, 4, 1, 2, 5, 6, 8, 1, 2, 0}

Série II: {1,1, 3, 0, 0, 2, 4, 1, 2, 5, 6, 8, 1, 2, 2, 0}

Série III: {1, 6, 8, 6, 5, 4, 3, 0, 3, 3, 0, 4, 4, 5, 6, 8, 2, 1, 1}

Série IV: {1, 6, 8, 8, 8, 6, 5, 5, 5, 4, 3, 0, 3, 3, 0, 4}

```
# Criar os vetores
S1 <- c(1, 3, 0, 0, 2, 4, 1, 2, 5, 6, 8, 1, 2, 0)
S2 <- c(1,1, 3, 0, 0, 2, 4, 1, 2, 5, 6, 8, 1, 2, 2, 0)
S3 <- c(1,6, 8, 6, 5, 4, 3, 0, 3, 3, 0, 4, 4, 5, 6, 8, 2, 1, 1)

table(S1)
## S1
## 0 1 2 3 4 5 6 8
## 3 3 3 1 1 1 1 1

table(S2)
## S2
## 0 1 2 3 4 5 6 8
## 3 4 4 1 1 1 1 1

table(S3)
## S3
## 0 1 2 3 4 5 6 8
## 2 3 1 3 3 2 3 2
```

Medidas de tendência central (ou posição)

Moda (Mo)

Vantagens

- Fácil de ser calculada;
- É a única medida de tendência central que pode ser usada para variáveis qualitativas; e
- Não é influenciada por valores extremos (*outliers*).

Limitações

- Pode não ser representativa; e
- Pode mudar se inserirmos novas observações.

Medidas de tendência central (ou posição)

Mediana (M_d) - Conceito

É o valor que ocupa a posição central de uma série de dados ordenados de forma crescente. Ou seja, em que 50% dos elementos devem estar abaixo da mediana e 50% devem estar acima da mediana.

É o valor que divide a série de dados ordenados em duas partes iguais.

Medidas de tendência central (ou posição)

Mediana (Md) - Como determinar?

- ☛ A determinação da Mediana (Md) requer encontrar o(s) elemento(s) que divide(m) os dados ordenados em duas partes iguais.
- ☛ Em geral, existem duas fórmulas para encontrar esse(s) elemento(s).
- ☛ O uso de cada uma é função do número de observações no conjunto de dados.

- **Número ímpar de observações**

$$E = \frac{n + 1}{2}$$

- **Número par de observações**

$$E = \frac{\left[\frac{n}{2} + \left(\frac{n}{2} + 1 \right) \right]}{2}$$

Medidas de tendência central (ou posição)

Mediana (Md) - Número ímpar de observações

Seja a série de dados S1:

$S1 = \{1, 3, 0, 0, 2, 4, 1, 2, 5, 6, 8, 1, 2, 2, 0\}$

Qual a mediana (Md)?

Procedimentos:

Passo 1: Ordenar o conjunto de dados:

$S1 = \{0, 0, 0, 1, 1, 1, 2, 2, 2, 2, 3, 4, 5, 6, 8\}$

Passo 2: Encontrar o elemento central (E):

$$E = \frac{n + 1}{2} = \frac{15 + 1}{2} = 8$$

Interpretação: O 8º elemento da série ordenada de dados é a mediana. $Md = 2$

$S1 = \{0, 0, 0, 1, 1, 1, 2, 2, 2, 2, 3, 4, 5, 6, 8\}$

Medidas de tendência central (ou posição)

Mediana (Md) - Número par de observações

Seja a série de dados S2:

$S2 = \{1, 3, 0, 0, 2, 4, 1, 5, 6, 8, 1, 0\}$

Qual a mediana (Md)?

Procedimentos:

Passo 1: Ordenar o conjunto de dados:

$S2 = \{0, 0, 0, 1, 1, 1, 2, 3, 4, 5, 6, 8\}$

Passo 2: Encontrar o elemento central (E):

$$E = \frac{\left[\frac{n}{2} + \left(\frac{n}{2} + 1\right)\right]}{2} = \frac{\left[\frac{12}{2} + \left(\frac{12}{2} + 1\right)\right]}{2} = \frac{(6 + 7)}{2} = 6,5$$

Interpretação: A mediana é a média aritmética entre o 6º e 7º elementos da série ordenada.

$Md = 1,5$

$S2 = \{0, 0, 0, 1, 1, 1, 2, 3, 4, 5, 6, 8\}$

Medidas de tendência central (ou posição)

Mediana (Md) - Usando a linguagem R

👉 O R-base possui uma função para calcular a mediana: `median()`.

👉 Esta função pertence ao pacote "stats".

Então, sejam as series:

S1 = {1, 3, 0, 0, 2, 4, 1, 2, 5, 6, 8, 1, 2, 2, 0}

S2 = {1, 3, 0, 0, 2, 4, 1, 5, 6, 8, 1, 0}

```
# Criar os vetores
S1 <- c(1, 3, 0, 0, 2, 4, 1, 2, 5, 6, 8, 1, 2, 2, 0)
S2 <- c(1, 3, 0, 0, 2, 4, 1, 5, 6, 8, 1, 0)

# Calcula a mediana
median(S1)
## [1] 2
median(S2)
## [1] 1.5
```

Medidas de tendência central (ou posição)

Mediana (M_d) - Propriedades

- **Estável:** Não sofre influência de valores discrepantes (*outliers*). Devido a isso, quando a distribuição amostral é assimétrica, a utilização da mediana torna-se mais interessante.
- **Número par de observações:** Nestes casos, a mediana será sempre a média aritmética dos dois elementos centrais dos dados ordenados;
- **Número ímpar de observações:** Nestes casos, haverá coincidência da mediana com um dos elementos dos dados ordenados.

Medidas de tendência central (ou posição)

Média Aritmética - Conceito

Matemático: É a razão entre a soma de todos os valores assumidos pela variável e o número de observações.

É a medida de tendência central mais comum, intensa e extensivamente utilizada (Ferreira, 2009).

👉 A média amostral é representada por $\bar{x}$ (lê-se "X-barra").

👉 A média populacional é representada por μ (lê-se "mi").

Medidas de tendência central (ou posição)

Média Aritmética - Expressão matemática do estimador

As expressões matemáticas para os estimadores de média aritmética (amostral e populacional) são:

- **Média aritmética amostral**

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n}$$

- **Média aritmética populacional**

$$\mu = \frac{x_1 + x_2 + \dots + x_N}{N}$$

Medidas de tendência central (ou posição)

Média Aritmética - Expressão matemática

Uma forma simplificada da expressão matemática é:

- **Média aritmética amostral**

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

- **Média aritmética populacional**

$$\mu = \frac{1}{N} \sum_{i=1}^N X_i$$

Em que:

$\sum$ (lê-se sigma) = Símbolo de somatório.

i = índice de variação dos elementos que deverão ser somados.

N = Número total de elementos da população.

n = Número total de elementos da amostra.

x = Variável quantitativa objeto de estudo.

Medidas de tendência central (ou posição)

Vamos praticar...

QF	H	D	V
I	17.5	16.07	0.2445
II	16.2	13.24	0.1634
III	15.2	17.89	0.2956
III	18	13.11	0.1734
I	17	14.36	0.1967
II	18.4	11.27	0.1256
I	13	8.5	0.0659
III	18	14.87	0.2345
II	17	14.93	0.2346
I	17.3	15.47	0.2298

Showing 1 to 10 of 10 entries

Previous

1

Next

Questão proposta

Suponha que foram medidas 10 árvores em um povoamento de *Tectona grandis*, cujos dados estão abaixo. Assim, pede-se:

- Determinar a mediana e a média aritmética para as variáveis contínuas.
- Determinar a moda para a variável qualidade de fuste.

Obs.: Faça os cálculos manuais e usando a linguagem R.

Medidas de tendência central (ou posição)

Vamos praticar...

QF	H	D	V
I	17.5	16.07	0.2445
II	16.2	13.24	0.1634
III	15.2	17.89	0.2956
III	18	13.11	0.1734
I	17	14.36	0.1967
II	18.4	11.27	0.1256
I	13	8.5	0.0659
III	18	14.87	0.2345
II	17	14.93	0.2346
I	17.3	15.47	0.2298

Showing 1 to 10 of 10 entries

Previous

1

Next

Cálculos manuais - Mediana

$$E = \frac{\left[\frac{10}{2} + \left(\frac{10}{2} + 1 \right) \right]}{2} = \frac{(5 + 6)}{2} = 5,5$$

- Ordenar os vetores

D = {8.50, 11.27, 13.11, 13.24, 14.36, 14.87, 14.93, 15.47, 16.07, 17.89}

H = {13.0, 15.2, 16.2, 17.0, 17.0, 17.3, 17.5, 18.0, 18.0, 18.4}

V = {0.0659, 0.1256, 0.1634, 0.1734, 0.1967, 0.2298, 0.2345, 0.2346, 0.2445, 0.2956}

- Mediana?

$$Md_D = 14.615; Md_H = 17.15; Md_V = 0.21325$$

Medidas de tendência central (ou posição)

Vamos praticar...

QF	H	D	V
I	17.5	16.07	0.2445
II	16.2	13.24	0.1634
III	15.2	17.89	0.2956
III	18	13.11	0.1734
I	17	14.36	0.1967
II	18.4	11.27	0.1256
I	13	8.5	0.0659
III	18	14.87	0.2345
II	17	14.93	0.2346
I	17.3	15.47	0.2298

Cálculos manuais - Média Aritmética

$$\bar{D} = \frac{139,71}{10} = 13,971 \text{ cm}$$

$$\bar{H} = \frac{167,60}{10} = 16,760 \text{ m}$$

$$\bar{V} = \frac{1,964}{10} = 0,1964 \text{ m}^3$$

Medidas de tendência central (ou posição)

Vamos praticar...

QF	H	D	V
I	17.5	16.07	0.2445
II	16.2	13.24	0.1634
III	15.2	17.89	0.2956
III	18	13.11	0.1734
I	17	14.36	0.1967
II	18.4	11.27	0.1256
I	13	8.5	0.0659
III	18	14.87	0.2345
II	17	14.93	0.2346
I	17.3	15.47	0.2298

Cálculos manuais - Moda

- Calcular a ocorrência de cada categoria:

I = **4** (Mais frequente)

II = 3

III = 3

Medidas de tendência central (ou posição)

Usando a linguagem R

- **Mediana**

```
median(df$D)
## [1] 14.615
median(df$H)
## [1] 17.15
median(df$V)
## [1] 0.21325
```

- **Média Aritmética**

```
mean(df$D)
## [1] 13.971
mean(df$H)
## [1] 16.76
mean(df$V)
## [1] 0.1964
```

- **Moda**

```
table(df$QF)
##
##      I   II  III
##      4    3    3
```


Obrigado!



@lmftca_ufpa



<https://www.lmftca.com.br/>



